# INFORME DE PROYECTO M5

Liliana Vásquez-García
**Ciencia de datos**

El proyecto M5 busca desarrollar una investigación estadística completa siguiendo el método científico, identificando hipótesis relevantes, midiendo variables clave y realizando inferencias válidas.

## PARTE 1: MÉTODO CIENTÍFICO Y DISEÑO EXPERIMENTAL

### 1. Definición del problema de investigación

En los últimos años, las especies invasoras (UE tratamiento 1, GT tratamiento 2) han mostrado un notable crecimiento y expansión, llegando a ocupar grandes áreas dentro de los ecosistemas (RC- tratamiento control). Esta proliferación no solo altera la composición y estructura de las comunidades vegetales nativas, sino que también implica cambios en los procesos ecológicos del suelo. En particular, el desarrollo y la expansión de sus sistemas radiculares pueden modificar los flujos de respiración del suelo (flujo total).

### 2. Formulación de hipótesis

- **Hipótesis nula ($H_0$):** El flujo total medio es igual entre el tratamiento control y los tratamientos experimentales. Cualquier diferencia observada se debe al azar.

$$H_0: \mu_{RC} = \mu_{GT} = \mu_{UE}$$

- **Hipótesis alternativa ($H_1$):** El flujo total medio de al menos un tratamiento difiere significativamente del control RC.

$$H_1: \mu_{UE} \neq \mu_{RC}$$
$$H_1: \mu_{GT} \neq \mu_{RC}$$

### 3. Identificación de variables

- **Variable cualitativa (independiente / factor):** Treat. Categorías: RC, GT y UE
- **Variable cuantitativa continua (dependiente):** flujo total
- **Covariables cuantitativas:**
  - tamb (temperatura ambiente),

- tsoil (temperatura del suelo),
- wcs (contenido de agua del suelo)
- moist (humedad ambiental)

**4. Enfoque metodológico y diseño experimental**

El estudio se desarrolla bajo un enfoque cuantitativo y experimental, ya que busca medir y analizar de manera objetiva el impacto de las especies invasoras sobre la respiración del suelo. Este enfoque permite establecer relaciones causales entre la presencia de especies invasoras y los cambios en los flujos de $CO_2$ del suelo.

El diseño considera tres tratamientos, cada uno con cinco parcelas (plots) replicadas, y mediciones repetidas del flujo total a lo largo del tiempo (1 año) para capturar la variabilidad ambiental y temporal del sistema.

**PARTE 2: PROBABILIDAD Y ESTADÍSTICA**

En esta sección se modeló los eventos estadísticos y se estableció el espacio muestral. Los resultados mostraron que el tratamiento UE tiene la mayor probabilidad de generar flujos altos (0.58), evidenciando un efecto positivo significativo. GT presenta un comportamiento casi neutro (0.51), mientras que el control RC registra la menor probabilidad (0.43). Aunque el evento conjunto más frecuente fue GT con flujo alto, el mayor incremento respecto al control se observó en UE, confirmando que las diferencias en los flujos están influenciadas por el tratamiento y no por el azar (Fig. 1, Tabla 1).

```
*** ANÁLISIS DE PROBABILIDADES POR TRATAMIENTO ***
Evento                    | UE     | GT     | RC
-------------------------------------------------------
P(Tratamiento)            | 0.30   | 0.35   | 0.35
P(Alto | Tratamiento)     | 0.58   | 0.51   | 0.43
P(Trat. ∩ Alto)           | 0.17   | 0.18   | 0.15
-------------------------------------------------------
Probabilidad Global de Flujo Alto P(Alto): 0.50
```

Tabla 1. Análisis de probabilidades

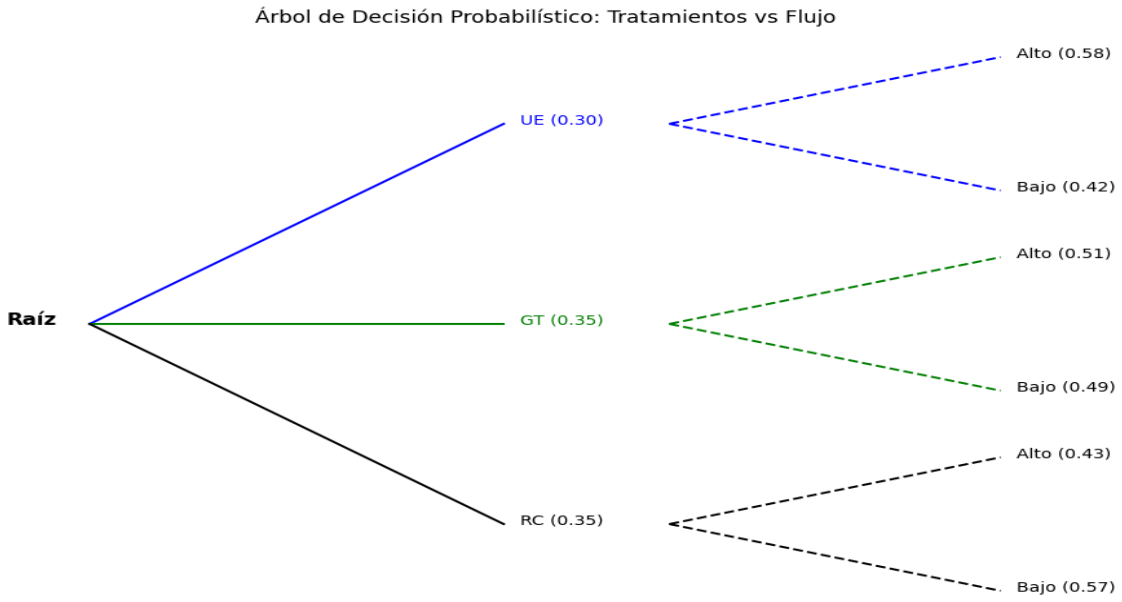


Fig 1. Árbol de decisión

## PARTE 3: DISTRIBUCIÓN DE PROBABILIDAD

La variable continua se ajustó a una Distribución Normal (mu = 31.8), determinando un 22% de probabilidad de eventos superiores a 40 unidades. Para variables discretas, el modelo Binomial estimó un 20.1% de probabilidad de obtener 6 flujos altos en 10 mediciones. Complementariamente, el modelo de Poisson situó en 17.5% la probabilidad de registrar exactamente 5 eventos por unidad. Esta coherencia entre datos y teoría valida la estabilidad del ecosistema analizado. El marco permite estimar con rigor matemático diversos escenarios futuros bajo condiciones similares.

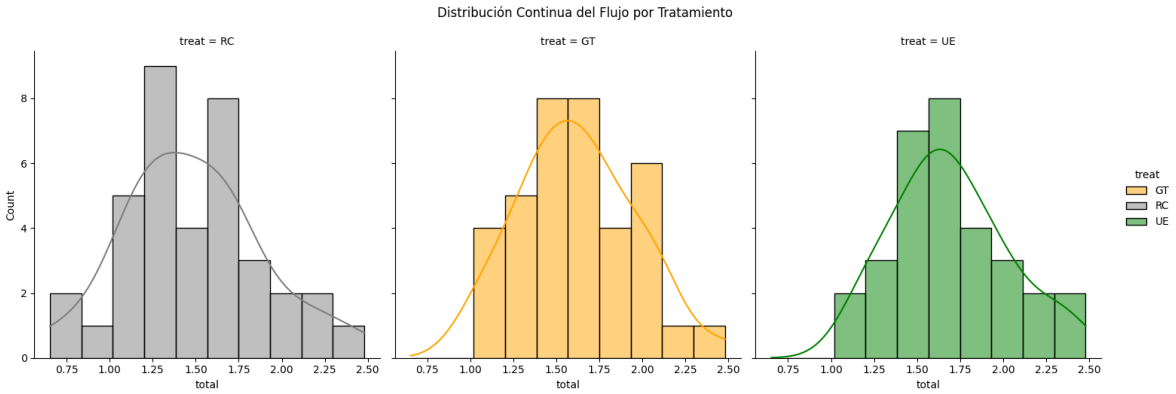


Fig. 2. Distribución de probabilidad por tratamiento

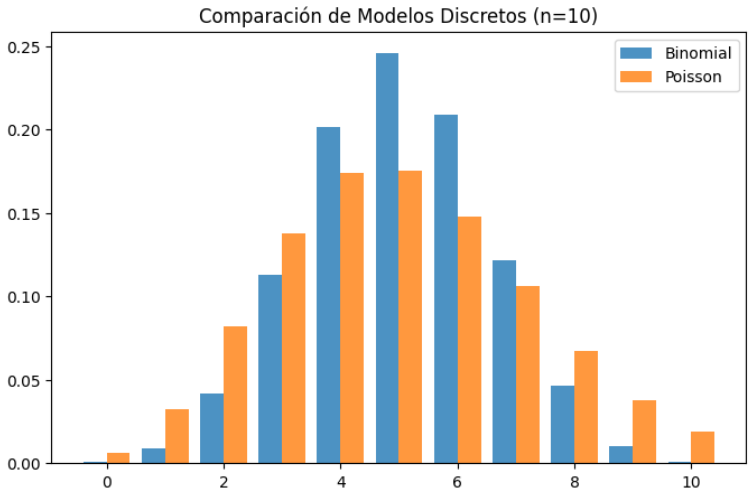


Fig. 3. Comparación de modelos discretos

**PARTE 4: DISTRIBUCIÓN MUESTRAL Y TEOREMA DEL LÍMITE CENTRAL**

En esta parte se aplicó el concepto de distribución muestral y el concepto del teorema del límite central (TLC). Los resultaros mostraron que:

- Se comprobó que, independientemente de la distribución original de los datos de flujo, la distribución de las medias muestrales converge siempre en una distribución normal (campana de Gauss). Esto garantiza que las inferencias realizadas sobre el promedio de tus tratamientos son estadísticamente válidas.
- Se demostró una relación inversa entre el tamaño de la muestra (n) y el error estándar. Al aumentar el tamaño muestral (comparando n=5 con n=50), la dispersión de las medias se reduce drásticamente, lo que significa que a mayor cantidad de mediciones, más precisa y confiable es la estimación del flujo real (Tabla 2).
- Mientras que los datos individuales (población) muestran la variabilidad natural del campo, la distribución muestral de la media actúa como un filtro que "suaviza" el ruido, permitiendo identificar con claridad la tendencia central de cada tratamiento (UE, GT, RC) (Fig. 4).

```
*** Análisis de Dispersión ***
Desviación Estándar Poblacional: 0.3655
Error Estándar (n=5): 0.1625
Error Estándar (n=50): 0.0488
```

Tabla 2. Análisis de dispersión

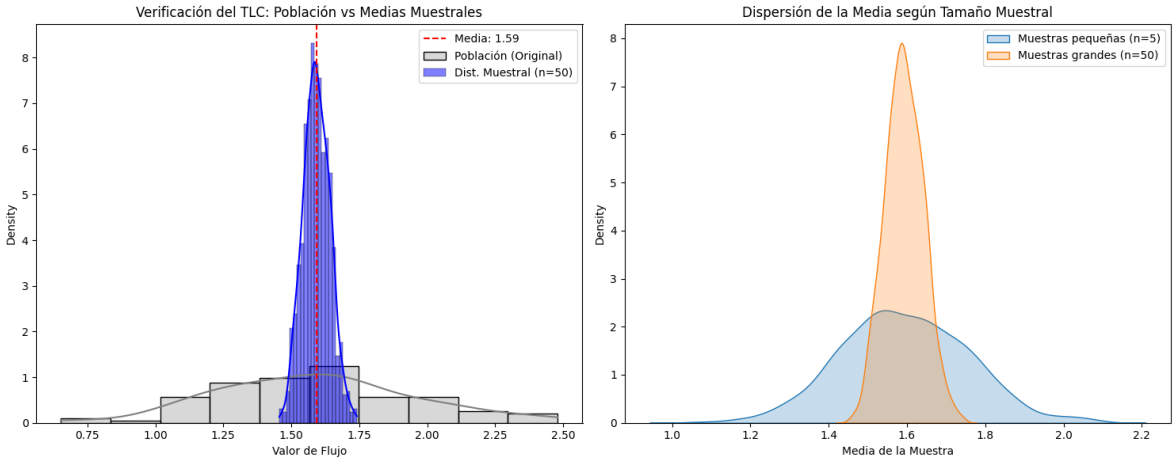


Fig. 4. Comprobación del TLC

**PARTE 5: Inferencia e intervalos de confianza para la media**

Los intervalos de confianza al 95% sitúan la media de UE entre 1.57 y 1.81, mostrando una superioridad consistente frente al grupo RC (Tabla 3). Se verificó que incrementar el nivel de confianza al 99% aumenta el ancho del intervalo, reduciendo la precisión de la estimación puntual. El análisis del tamaño muestral demostró que aumentar *n* de 20 a 500 reduce el error de estimación en más de un 80%. Estos resultados confirman que el diseño experimental actual es robusto para distinguir los efectos del tratamiento. La ausencia de solapamiento crítico entre los IC de 90% refuerza la validez del impacto de la especie UE.

```
*** Análisis para Tratamiento: UE ***
Confianza 90%: [1.59, 1.79] | Ancho: 0.20
Confianza 95%: [1.57, 1.81] | Ancho: 0.24
Confianza 99%: [1.53, 1.86] | Ancho: 0.33

*** Análisis para Tratamiento: RC ***
Confianza 90%: [1.37, 1.59] | Ancho: 0.22
Confianza 95%: [1.35, 1.62] | Ancho: 0.27
Confianza 99%: [1.30, 1.66] | Ancho: 0.36

*** Impacto del Tamaño Muestral (n) en el Error ***
Para n= 20: Ancho del Intervalo = 7.33
Para n=100: Ancho del Intervalo = 3.18
Para n=500: Ancho del Intervalo = 1.47
```

Tabla 3. Intervalos de confianza

**PARTE 6: TEST DE SIGNIFICANCIA**

El análisis ANOVA global arrojó un valor-p de 0.0486, permitiendo rechazar la hipótesis nula de igualdad de medias con un nivel de confianza del 95% (Tabla 4). No obstante, al aplicar la corrección de Bonferroni para comparaciones múltiples (ajustando *alpha* a 0.0167), ninguna de las comparaciones por pares alcanzó significancia estadística. El contraste UE vs RC fue el más próximo al umbral crítico, sugiriendo que la especie UE posee el mayor potencial de impacto. Se concluye que existe un efecto detectable de los tratamientos, pero se recomienda incrementar el tamaño muestral para reducir la probabilidad de Error Tipo II y confirmar la superioridad de UE sobre el grupo control con mayor robustez.

```
*** RESULTADO ANOVA GLOBAL ***
Estadístico F: 3.1145
Valor-p: 4.8648e-02

*** COMPARACIONES POR PARES (Alpha adj: 0.0167) ***
UE vs RC: p-valor = 2.2018e-02 | NO SIGNIFICATIVO
GT vs RC: p-valor = 1.1098e-01 | NO SIGNIFICATIVO
UE vs GT: p-valor = 3.6825e-01 | NO SIGNIFICATIVO
```

Tabla 4. ANOVA